

Teori Image Feature Extraction

Ryan Fadhilah Faizal Hakim¹

¹Sains Data, Fakultas Sains dan Teknologi, IKOPIN University

1 Pendahuluan

Image feature extraction atau ekstraksi fitur citra adalah proses mentransformasikan data citra mentah menjadi sekumpulan representasi numerik yang lebih ringkas, informatif, dan relevan untuk tugas analisis, seperti klasifikasi, deteksi objek, segmentasi, temu-kembali citra, pelacakan, pengenalan wajah, pengenalan tekstur, dan diagnosis berbasis citra medis. Citra digital pada dasarnya merupakan fungsi diskret dua dimensi. Untuk citra keabuan, citra dapat ditulis sebagai

$$I : \Omega \subset \mathbb{Z}^2 \rightarrow \mathbb{R}, \quad I(x, y) = \text{intensitas piksel pada koordinat } (x, y), \quad (1)$$

sedangkan untuk citra berwarna dengan tiga kanal RGB,

$$I : \Omega \subset \mathbb{Z}^2 \rightarrow \mathbb{R}^3, \quad I(x, y) = [R(x, y), G(x, y), B(x, y)]^T. \quad (2)$$

Ekstraksi fitur bertujuan membangun pemetaan

$$\phi(I) = \mathbf{f} \in \mathbb{R}^d, \quad (3)$$

dengan ϕ sebagai fungsi ekstraktor fitur dan $\mathbf{f}$ sebagai vektor fitur berdimensi d . Vektor fitur yang baik harus mampu mempertahankan informasi diskriminatif, mengurangi redundansi, tahan terhadap gangguan, dan sebisa mungkin invarian terhadap perubahan yang tidak relevan seperti translasi, rotasi, perubahan skala, iluminasi, atau derau.

Dalam konteks pembelajaran mesin, ekstraksi fitur berperan sebagai jembatan antara citra mentah berdimensi tinggi dan model keputusan. Jika citra berukuran $M \times N$ dengan C kanal, representasi piksel mentah mempunyai dimensi MNC . Dimensi ini sering terlalu besar, rentan terhadap derau, dan tidak selalu merepresentasikan struktur semantik. Karena itu fitur dirancang agar lebih padat, misalnya fitur warna, tekstur, bentuk, tepi, titik kunci lokal, transformasi frekuensi, atau fitur mendalam dari jaringan saraf konvolusional.

2 Konsep Dasar Citra Digital

2.1 Representasi Citra

Citra digital dapat dipandang sebagai matriks intensitas

$$I = \begin{bmatrix} I(1,1) & I(1,2) & \cdots & I(1,N) \\ I(2,1) & I(2,2) & \cdots & I(2,N) \\ \vdots & \vdots & \ddots & \vdots \\ I(M,1) & I(M,2) & \cdots & I(M,N) \end{bmatrix}, \quad (4)$$

dengan M menyatakan tinggi citra dan N menyatakan lebar citra. Untuk citra berwarna, matriks tersebut menjadi tensor orde tiga $I \in \mathbb{R}^{M \times N \times C}$.

Nilai intensitas biasanya berada pada rentang $[0, 255]$ untuk citra 8-bit, atau dinormalisasi menjadi $[0, 1]$ melalui

$$I_{\text{norm}}(x, y) = \frac{I(x, y) - I_{\min}}{I_{\max} - I_{\min}}. \quad (5)$$

Normalisasi ini penting agar fitur tidak didominasi oleh skala intensitas tertentu.

2.2 Pra-pemrosesan Sebelum Ekstraksi Fitur

Pra-pemrosesan dilakukan untuk meningkatkan kualitas citra dan menstabilkan fitur. Beberapa operasi umum adalah sebagai berikut.

2.2.1 Konversi Warna ke Grayscale

Citra RGB sering dikonversi menjadi citra keabuan menggunakan kombinasi linear

$$Y(x, y) = 0.299R(x, y) + 0.587G(x, y) + 0.114B(x, y), \quad (6)$$

dengan Y sebagai luminansi. Bobot tersebut mengikuti sensitivitas visual manusia yang lebih peka terhadap kanal hijau dibandingkan merah dan biru.

2.2.2 Penyaringan Derau

Derau dapat mengganggu pendeteksian tepi, tekstur, dan titik kunci. Salah satu penyaring paling umum adalah Gaussian filter

$$G_{\sigma}(x, y) = \frac{1}{2\pi\sigma^2} \exp\left(-\frac{x^2 + y^2}{2\sigma^2}\right), \quad (7)$$

dengan citra hasil penghalusan

$$I_s(x, y) = (G_\sigma * I)(x, y) = \sum_u \sum_v G_\sigma(u, v) I(x - u, y - v). \quad (8)$$

Parameter σ mengontrol tingkat penghalusan. Nilai σ besar mengurangi derau lebih kuat, tetapi dapat menghilangkan detail kecil.

2.2.3 Standardisasi Intensitas

Standardisasi membuat distribusi intensitas memiliki rata-rata nol dan simpangan baku satu:

$$I_z(x, y) = \frac{I(x, y) - \mu_I}{\sigma_I}, \quad (9)$$

dengan

$$\mu_I = \frac{1}{MN} \sum_{x=1}^M \sum_{y=1}^N I(x, y), \quad \sigma_I = \sqrt{\frac{1}{MN} \sum_{x=1}^M \sum_{y=1}^N (I(x, y) - \mu_I)^2}. \quad (10)$$

3 Sifat Fitur Citra yang Baik

Fitur citra yang baik umumnya memiliki beberapa sifat berikut.

1. **Diskriminatif**, yaitu mampu membedakan kelas atau objek yang berbeda.
2. **Robust**, yaitu stabil terhadap derau, blur, kompresi, atau variasi pencahayaan.
3. **Invarian**, yaitu tidak berubah secara signifikan terhadap transformasi tidak relevan seperti translasi, rotasi, dan skala.
4. **Kompak**, yaitu berdimensi cukup rendah agar efisien secara komputasi.
5. **Reproducible**, yaitu menghasilkan fitur yang konsisten untuk citra yang sama atau citra serupa.
6. **Interpretabel**, terutama pada fitur tradisional seperti histogram warna, tekstur, dan bentuk.

Secara matematis, invarian terhadap transformasi T dapat ditulis sebagai

$$\phi(T(I)) \approx \phi(I). \quad (11)$$

Sementara itu, sifat diskriminatif dapat dinyatakan melalui jarak antarfitur. Untuk dua citra dari kelas berbeda, diharapkan

$$d(\phi(I_a), \phi(I_b)) \text{ besar jika } y_a \neq y_b, \quad (12)$$

dan untuk kelas yang sama,

$$d(\phi(I_a), \phi(I_b)) \text{ kecil jika } y_a = y_b. \quad (13)$$

4 Taksonomi Image Feature Extraction

Metode ekstraksi fitur citra dapat dikelompokkan menjadi beberapa kategori besar.

Kategori	Contoh	Informasi yang Ditangkap
Fitur warna	Histogram RGB, HSV, color moments	Distribusi warna dan komposisi kanal
Fitur tepi	Sobel, Prewitt, Canny	Perubahan intensitas dan batas objek
Fitur tekstur	GLCM, LBP, Gabor, wavelet	Pola lokal, kekasaran, repetisi, orientasi
Fitur bentuk	Kontur, momen, Fourier descriptor	Geometri objek dan struktur batas
Fitur lokal	Harris, SIFT, SURF, ORB	Titik kunci dan deskriptor lokal
Fitur frekuensi	DFT, DCT, wavelet	Komponen spektral dan energi frekuensi
Fitur mendalam	CNN, autoencoder, Vision Transformer	Representasi hierarkis dan semantik

Table 1: Kategori utama metode ekstraksi fitur citra.

5 Fitur Warna

5.1 Histogram Warna

Histogram warna mendeskripsikan distribusi intensitas atau warna dalam citra. Untuk citra grayscale dengan L tingkat intensitas, histogram didefinisikan sebagai

$$h(k) = \sum_{x=1}^M \sum_{y=1}^N \delta(I(x, y) - k), \quad k = 0, 1, \dots, L - 1, \quad (14)$$

dengan fungsi indikator

$$\delta(a) = \begin{cases} 1, & a = 0, \\ 0, & a \neq 0. \end{cases} \quad (15)$$

Histogram sering dinormalisasi menjadi distribusi probabilitas

$$p(k) = \frac{h(k)}{MN}, \quad \sum_{k=0}^{L-1} p(k) = 1. \quad (16)$$

Untuk citra RGB, histogram dapat dihitung per kanal:

$$\mathbf{h}_{RGB} = [\mathbf{h}_R, \mathbf{h}_G, \mathbf{h}_B]. \quad (17)$$

Kelebihan histogram warna adalah sederhana dan efisien, tetapi kelemahannya adalah mengabaikan informasi spasial. Dua citra dengan susunan objek berbeda dapat mempunyai histogram warna yang sama.

5.2 Ruang Warna HSV dan Normalized RGB

Ruang warna RGB sensitif terhadap pencahayaan. Oleh karena itu, fitur warna sering dihitung pada ruang warna lain seperti HSV, Lab, atau normalized RGB. Normalized RGB didefinisikan sebagai

$$r = \frac{R}{R+G+B}, \quad g = \frac{G}{R+G+B}, \quad b = \frac{B}{R+G+B}, \quad (18)$$

dengan $r + g + b = 1$. Representasi ini mengurangi pengaruh perubahan intensitas global.

Pada ruang HSV, warna direpresentasikan oleh hue H , saturation S , dan value V . Komponen H menggambarkan jenis warna, S menggambarkan kemurnian warna, dan V menggambarkan kecerahan.

5.3 Color Moments

Color moments menggunakan momen statistik distribusi warna. Untuk kanal warna c , rata-rata, simpangan baku, dan skewness didefinisikan sebagai

$$\mu_c = \frac{1}{MN} \sum_{x=1}^M \sum_{y=1}^N I_c(x, y), \quad (19)$$

$$\sigma_c = \sqrt{\frac{1}{MN} \sum_{x=1}^M \sum_{y=1}^N (I_c(x, y) - \mu_c)^2}, \quad (20)$$

$$s_c = \sqrt[3]{\frac{1}{MN} \sum_{x=1}^M \sum_{y=1}^N (I_c(x, y) - \mu_c)^3}. \quad (21)$$

Vektor fitur color moments untuk RGB dapat ditulis sebagai

$$\mathbf{f}_{\text{color}} = [\mu_R, \sigma_R, s_R, \mu_G, \sigma_G, s_G, \mu_B, \sigma_B, s_B]^T. \quad (22)$$

6 Fitur Tepi dan Gradien

6.1 Gradien Citra

Tepi merupakan lokasi perubahan intensitas yang tajam. Gradien citra didefinisikan sebagai

$$\nabla I(x, y) = \begin{bmatrix} \frac{\partial I}{\partial x} \\ \frac{\partial I}{\partial y} \end{bmatrix}. \quad (23)$$

Magnitudo dan orientasi gradien adalah

$$m(x, y) = \sqrt{I_x(x, y)^2 + I_y(x, y)^2}, \quad (24)$$

$$\theta(x, y) = \arctan \left(\frac{I_y(x, y)}{I_x(x, y)} \right). \quad (25)$$

Dalam citra digital, turunan dihampiri menggunakan operator konvolusi.

6.2 Operator Sobel

Operator Sobel menggunakan dua kernel

$$K_x = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix}, \quad K_y = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix}. \quad (26)$$

Komponen gradien dihitung melalui

$$I_x = K_x * I, \quad I_y = K_y * I. \quad (27)$$

Fitur tepi dapat berupa jumlah piksel tepi, histogram orientasi tepi, atau statistik magnitudo gradien.

6.3 Detektor Tepi Canny

Detektor Canny merupakan metode populer karena menghasilkan tepi yang tipis dan relatif stabil. Tahapannya meliputi:

1. menghaluskan citra dengan Gaussian filter;
2. menghitung gradien I_x , I_y , magnitudo m , dan orientasi θ ;
3. melakukan *non-maximum suppression*;
4. menerapkan ambang ganda T_{low} dan T_{high} ;
5. melakukan *edge tracking by hysteresis*.

Secara sederhana, piksel kuat dan lemah dapat ditentukan dengan

$$E(x, y) = \begin{cases} \text{strong edge,} & m(x, y) \geq T_{high}, \\ \text{weak edge,} & T_{low} \leq m(x, y) < T_{high}, \\ \text{non-edge,} & m(x, y) < T_{low}. \end{cases} \quad (28)$$

7 Fitur Tekstur

Tekstur menggambarkan pola perubahan intensitas yang berulang atau terstruktur. Fitur tekstur penting untuk mengenali permukaan seperti kain, kayu, kulit, daun, jaringan medis, dan citra satelit.

7.1 Gray Level Co-occurrence Matrix

Gray Level Co-occurrence Matrix (GLCM) menghitung seberapa sering pasangan intensitas tertentu muncul pada jarak dan orientasi tertentu. Untuk citra dengan L tingkat keabuan, GLCM $P(i, j; d, \theta)$ didefinisikan sebagai jumlah pasangan piksel dengan intensitas i dan j yang dipisahkan oleh offset $(\Delta x, \Delta y)$:

$$P(i, j) = \#\{((x, y), (x + \Delta x, y + \Delta y)) \mid I(x, y) = i, I(x + \Delta x, y + \Delta y) = j\}. \quad (29)$$

GLCM biasanya dinormalisasi:

$$p(i, j) = \frac{P(i, j)}{\sum_{i=0}^{L-1} \sum_{j=0}^{L-1} P(i, j)}. \quad (30)$$

Beberapa fitur Haralick yang umum dari GLCM adalah:

$$\text{Contrast} = \sum_{i=0}^{L-1} \sum_{j=0}^{L-1} (i - j)^2 p(i, j), \quad (31)$$

$$\text{Energy} = \sum_{i=0}^{L-1} \sum_{j=0}^{L-1} p(i, j)^2, \quad (32)$$

$$\text{Homogeneity} = \sum_{i=0}^{L-1} \sum_{j=0}^{L-1} \frac{p(i, j)}{1 + |i - j|}, \quad (33)$$

$$\text{Entropy} = - \sum_{i=0}^{L-1} \sum_{j=0}^{L-1} p(i, j) \log(p(i, j) + \epsilon). \quad (34)$$

Korelasi GLCM dapat ditulis sebagai

$$\text{Correlation} = \sum_{i=0}^{L-1} \sum_{j=0}^{L-1} \frac{(i - \mu_i)(j - \mu_j)p(i, j)}{\sigma_i \sigma_j}, \quad (35)$$

dengan μ_i , μ_j , σ_i , dan σ_j adalah rata-rata serta simpangan baku marginal GLCM.

7.2 Local Binary Pattern

Local Binary Pattern (LBP) mendeskripsikan pola tekstur lokal dengan membandingkan intensitas piksel tetangga terhadap piksel pusat. Untuk P tetangga pada radius R , LBP didefinisikan sebagai

$$\text{LBP}_{P,R}(x_c, y_c) = \sum_{p=0}^{P-1} s(I_p - I_c) 2^p, \quad (36)$$

dengan

$$s(z) = \begin{cases} 1, & z \geq 0, \\ 0, & z < 0. \end{cases} \quad (37)$$

I_c adalah intensitas piksel pusat dan I_p adalah intensitas tetangga ke- p . Fitur akhir biasanya berupa histogram kode LBP:

$$h(k) = \sum_{x,y} \delta(\text{LBP}_{P,R}(x,y) - k). \quad (38)$$

LBP kuat untuk tekstur lokal dan relatif tahan terhadap perubahan iluminasi monoton.

7.3 Filter Gabor

Filter Gabor menangkap informasi frekuensi lokal dan orientasi. Filter Gabor dua dimensi dapat ditulis sebagai

$$g(x, y; \lambda, \theta, \psi, \sigma, \gamma) = \exp\left(-\frac{x'^2 + \gamma^2 y'^2}{2\sigma^2}\right) \cos\left(2\pi \frac{x'}{\lambda} + \psi\right), \quad (39)$$

dengan

$$x' = x \cos \theta + y \sin \theta, \quad y' = -x \sin \theta + y \cos \theta. \quad (40)$$

Parameter λ mengatur panjang gelombang, θ mengatur orientasi, ψ fase, σ lebar Gaussian, dan γ rasio aspek. Respons filter adalah

$$R_{\lambda,\theta}(x, y) = (I * g_{\lambda,\theta})(x, y). \quad (41)$$

Fitur Gabor dapat berupa energi respons

$$E_{\lambda,\theta} = \sum_{x=1}^M \sum_{y=1}^N |R_{\lambda,\theta}(x, y)|^2. \quad (42)$$

8 Fitur Bentuk

Fitur bentuk digunakan ketika objek dapat dipisahkan dari latar belakang. Bentuk dapat direpresentasikan melalui kontur, area, perimeter, momen, atau deskriptor frekuensi.

8.1 Fitur Geometris Dasar

Misalkan S adalah himpunan piksel objek hasil segmentasi. Luas objek adalah

$$A = |S| = \sum_{x,y} \mathbf{1}\{(x, y) \in S\}. \quad (43)$$

Perimeter P dapat dihitung dari panjang batas objek. Beberapa fitur bentuk dasar meliputi:

$$\text{Compactness} = \frac{P^2}{4\pi A}, \quad (44)$$

$$\text{Circularity} = \frac{4\pi A}{P^2}, \quad (45)$$

$$\text{Aspect Ratio} = \frac{w}{h}, \quad (46)$$

$$\text{Rectangularity} = \frac{A}{wh}, \quad (47)$$

dengan w dan h adalah lebar serta tinggi kotak pembatas.

8.2 Momen Citra

Momen spasial orde (p, q) didefinisikan sebagai

$$m_{pq} = \sum_x \sum_y x^p y^q I(x, y). \quad (48)$$

Pusat massa citra adalah

$$\bar{x} = \frac{m_{10}}{m_{00}}, \quad \bar{y} = \frac{m_{01}}{m_{00}}. \quad (49)$$

Momen pusat adalah

$$\mu_{pq} = \sum_x \sum_y (x - \bar{x})^p (y - \bar{y})^q I(x, y). \quad (50)$$

Momen pusat ternormalisasi ditulis sebagai

$$\eta_{pq} = \frac{\mu_{pq}}{\mu_{00}^\gamma}, \quad \gamma = \frac{p+q}{2} + 1. \quad (51)$$

Momen Hu adalah kombinasi momen ternormalisasi yang invarian terhadap translasi, skala, dan rotasi. Dua contoh momen Hu adalah

$$\phi_1 = \eta_{20} + \eta_{02}, \quad (52)$$

$$\phi_2 = (\eta_{20} - \eta_{02})^2 + 4\eta_{11}^2. \quad (53)$$

9 Fitur Lokal dan Titik Kunci

Fitur lokal mengekstraksi informasi dari titik-titik penting citra. Pendekatan ini berguna ketika citra mengalami perubahan sudut pandang, skala, rotasi, atau sebagian objek tertutup.

9.1 Detektor Sudut Harris

Detektor Harris mencari titik dengan perubahan intensitas besar dalam dua arah. Untuk pergeseran kecil (u, v) , perubahan intensitas lokal didefinisikan sebagai

$$E(u, v) = \sum_{x,y} w(x, y) [I(x + u, y + v) - I(x, y)]^2. \quad (54)$$

Dengan pendekatan Taylor orde pertama,

$$I(x + u, y + v) \approx I(x, y) + uI_x + vI_y. \quad (55)$$

Maka

$$E(u, v) \approx \begin{bmatrix} u & v \end{bmatrix} \mathbf{M} \begin{bmatrix} u \\ v \end{bmatrix}, \quad (56)$$

dengan matriks struktur

$$\mathbf{M} = \sum_{x,y} w(x, y) \begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix}. \quad (57)$$

Respons Harris adalah

$$R = \det(\mathbf{M}) - k(\text{trace}(\mathbf{M}))^2, \quad (58)$$

dengan k biasanya bernilai kecil. Titik dengan R besar positif dianggap sebagai sudut.

9.2 Scale-Invariant Feature Transform

Scale-Invariant Feature Transform (SIFT) dirancang agar relatif invarian terhadap skala dan rotasi. SIFT membangun ruang skala menggunakan Gaussian:

$$L(x, y, \sigma) = G(x, y, \sigma) * I(x, y). \quad (59)$$

Titik kunci dicari melalui Difference of Gaussian (DoG):

$$D(x, y, \sigma) = L(x, y, k\sigma) - L(x, y, \sigma). \quad (60)$$

Ekstremum lokal pada $D(x, y, \sigma)$ menjadi kandidat titik kunci. Orientasi dominan dihitung dari gradien lokal, kemudian deskriptor dibentuk dari histogram orientasi gradien pada blok-blok lokal. Secara umum, deskriptor SIFT klasik berdimensi $4 \times 4 \times 8 = 128$.

9.3 Speeded-Up Robust Features dan ORB

Speeded-Up Robust Features (SURF) mempercepat ide SIFT dengan pendekatan Hessian dan integral image. Matriks Hessian pada titik (x, y) dan skala σ adalah

$$\mathbf{H}(x, y, \sigma) = \begin{bmatrix} L_{xx}(x, y, \sigma) & L_{xy}(x, y, \sigma) \\ L_{xy}(x, y, \sigma) & L_{yy}(x, y, \sigma) \end{bmatrix}. \quad (61)$$

Titik kunci dipilih berdasarkan determinan Hessian.

ORB menggabungkan FAST corner detector dan BRIEF descriptor yang diorientasikan. Deskriptor biner seperti BRIEF membandingkan pasangan piksel lokal:

$$\tau(p_a, p_b) = \begin{cases} 1, & I(p_a) < I(p_b), \\ 0, & I(p_a) \geq I(p_b). \end{cases} \quad (62)$$

Deskriptor biner cocok untuk pencocokan cepat menggunakan Hamming distance:

$$d_H(\mathbf{a}, \mathbf{b}) = \sum_{i=1}^d \mathbf{1}\{a_i \neq b_i\}. \quad (63)$$

10 Histogram of Oriented Gradients

Histogram of Oriented Gradients (HOG) adalah fitur berbasis gradien yang populer untuk deteksi objek. Ide utamanya adalah bentuk lokal dapat direpresentasikan oleh distribusi arah gradien.

Tahapan HOG adalah:

1. menghitung gradien I_x dan I_y ;
2. menghitung magnitudo m dan orientasi θ ;
3. membagi citra menjadi sel kecil;
4. membuat histogram orientasi pada setiap sel dengan bobot magnitudo;
5. menormalisasi histogram dalam blok yang lebih besar.

Jika terdapat B bin orientasi, kontribusi piksel ke bin b dapat ditulis sebagai

$$h_b = \sum_{(x,y) \in \text{cell}} m(x,y) \mathbf{1}\{\theta(x,y) \in \mathcal{B}_b\}. \quad (64)$$

Normalisasi blok sering menggunakan L2-norm:

$$\hat{\mathbf{h}} = \frac{\mathbf{h}}{\sqrt{\|\mathbf{h}\|_2^2 + \epsilon^2}}. \quad (65)$$

Normalisasi ini membuat HOG lebih tahan terhadap perubahan pencahayaan lokal.

11 Fitur Domain Frekuensi

11.1 Discrete Fourier Transform

Transformasi Fourier diskret dua dimensi mengubah citra dari domain spasial ke domain frekuensi:

$$F(u, v) = \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} I(x, y) \exp \left[-j2\pi \left(\frac{ux}{M} + \frac{vy}{N} \right) \right]. \quad (66)$$

Transformasi inversnya adalah

$$I(x, y) = \frac{1}{MN} \sum_{u=0}^{M-1} \sum_{v=0}^{N-1} F(u, v) \exp \left[j2\pi \left(\frac{ux}{M} + \frac{vy}{N} \right) \right]. \quad (67)$$

Magnitudo spektrum

$$|F(u, v)| = \sqrt{\text{Re}(F(u, v))^2 + \text{Im}(F(u, v))^2} \quad (68)$$

dapat digunakan sebagai fitur frekuensi. Frekuensi rendah merepresentasikan struktur global, sedangkan frekuensi tinggi merepresentasikan detail dan tepi.

11.2 Discrete Cosine Transform

Discrete Cosine Transform (DCT) banyak digunakan dalam kompresi dan ekstraksi fitur karena energi citra sering terkonsentrasi pada koefisien frekuensi rendah. DCT dua dimensi didefinisikan sebagai

$$C(u, v) = \alpha(u)\alpha(v) \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} I(x, y) \cos \left[\frac{\pi(2x+1)u}{2M} \right] \cos \left[\frac{\pi(2y+1)v}{2N} \right], \quad (69)$$

dengan

$$\alpha(u) = \begin{cases} \sqrt{\frac{1}{M}}, & u = 0, \\ \sqrt{\frac{2}{M}}, & u > 0. \end{cases} \quad (70)$$

Koefisien DCT frekuensi rendah sering dipilih sebagai fitur karena lebih stabil terhadap derau kecil.

11.3 Wavelet

Transformasi wavelet merepresentasikan citra pada berbagai skala. Dekomposisi wavelet dua dimensi menghasilkan subband LL, LH, HL, dan HH. Subband LL berisi aproksimasi frekuensi rendah, sedangkan LH, HL, dan HH berisi detail horizontal, vertikal, dan diagonal. Energi subband dapat dijadikan fitur:

$$E_s = \sum_{(x,y) \in s} |W_s(x, y)|^2, \quad (71)$$

dengan $s \in \{LL, LH, HL, HH\}$.

12 Fitur Berbasis Pembelajaran Mendalam

12.1 Convolutional Neural Network

Pada pendekatan modern, fitur sering dipelajari secara otomatis menggunakan Convolutional Neural Network (CNN). Operasi konvolusi pada layer ke- l dapat ditulis sebagai

$$Z_k^{(l)}(x, y) = \sum_{c=1}^{C_{l-1}} \sum_u \sum_v W_{k,c}^{(l)}(u, v) A_c^{(l-1)}(x - u, y - v) + b_k^{(l)}, \quad (72)$$

dengan $W_{k,c}^{(l)}$ adalah kernel, $A_c^{(l-1)}$ adalah aktivasi dari layer sebelumnya, dan $b_k^{(l)}$ adalah bias. Aktivasi nonlinear, misalnya ReLU, diberikan oleh

$$A_k^{(l)}(x, y) = \max(0, Z_k^{(l)}(x, y)). \quad (73)$$

Pooling mengurangi resolusi spasial dan meningkatkan toleransi terhadap translasi kecil. Max pooling didefinisikan sebagai

$$A_k^{(l)}(i, j) = \max_{(x,y) \in \mathcal{R}_{ij}} A_k^{(l-1)}(x, y). \quad (74)$$

CNN mempelajari hierarki fitur. Layer awal biasanya menangkap tepi dan warna sederhana, layer menengah menangkap motif atau tekstur, sedangkan layer dalam menangkap bagian objek dan konsep semantik.

12.2 Transfer Learning sebagai Ekstraksi Fitur

Dalam transfer learning, model CNN yang telah dilatih pada dataset besar digunakan sebagai ekstraktor fitur. Jika g_θ adalah CNN pra-latih, fitur citra dapat ditulis sebagai

$$\mathbf{f} = g_\theta(I), \quad (75)$$

kemudian digunakan oleh model klasifikasi seperti SVM, k-NN, random forest, atau multilayer perceptron. Pendekatan ini efektif ketika dataset target kecil.

12.3 Autoencoder

Autoencoder mempelajari representasi laten dengan merekonstruksi input. Encoder memetakan citra ke ruang laten:

$$\mathbf{z} = f_\theta(I), \quad (76)$$

sedangkan decoder merekonstruksi citra:

$$\hat{I} = g_\psi(\mathbf{z}). \quad (77)$$

Fungsi loss rekonstruksi yang umum adalah

$$\mathcal{L}_{\text{rec}} = \|I - \hat{I}\|_2^2. \quad (78)$$

Vektor laten $\mathbf{z}$ digunakan sebagai fitur kompak.

13 Reduksi Dimensi dan Seleksi Fitur

Ekstraksi fitur sering menghasilkan vektor berdimensi tinggi. Reduksi dimensi diperlukan untuk mengurangi kompleksitas, menghindari *curse of dimensionality*, dan meningkatkan generalisasi.

13.1 Principal Component Analysis

Principal Component Analysis (PCA) mencari proyeksi linear yang memaksimalkan variansi data. Misalkan terdapat n vektor fitur $\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^d$. Rata-rata data adalah

$$\boldsymbol{\mu} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i. \quad (79)$$

Matriks kovarians adalah

$$\mathbf{S} = \frac{1}{n-1} \sum_{i=1}^n (\mathbf{x}_i - \boldsymbol{\mu})(\mathbf{x}_i - \boldsymbol{\mu})^T. \quad (80)$$

PCA menyelesaikan masalah eigen

$$\mathbf{S}\mathbf{u}_k = \lambda_k \mathbf{u}_k, \quad (81)$$

dengan λ_k sebagai eigenvalue dan $\mathbf{u}_k$ sebagai eigenvector. Proyeksi ke r komponen utama adalah

$$\mathbf{z} = \mathbf{U}_r^T (\mathbf{x} - \boldsymbol{\mu}). \quad (82)$$

13.2 Linear Discriminant Analysis

Linear Discriminant Analysis (LDA) mencari proyeksi yang memaksimalkan separasi antar kelas dan meminimalkan variasi dalam kelas. Matriks sebar dalam kelas adalah

$$\mathbf{S}_W = \sum_{c=1}^C \sum_{\mathbf{x}_i \in c} (\mathbf{x}_i - \boldsymbol{\mu}_c)(\mathbf{x}_i - \boldsymbol{\mu}_c)^T, \quad (83)$$

sedangkan matriks sebar antar kelas adalah

$$\mathbf{S}_B = \sum_{c=1}^C n_c (\boldsymbol{\mu}_c - \boldsymbol{\mu})(\boldsymbol{\mu}_c - \boldsymbol{\mu})^T. \quad (84)$$

Tujuannya adalah memaksimalkan

$$J(\mathbf{W}) = \frac{|\mathbf{W}^T \mathbf{S}_B \mathbf{W}|}{|\mathbf{W}^T \mathbf{S}_W \mathbf{W}|}. \quad (85)$$

14 Normalisasi dan Pengukuran Kemiripan Fitur

Setelah fitur diekstraksi, fitur sering dinormalisasi agar setiap komponen memiliki skala sebanding. Min-max normalization diberikan oleh

$$x'_j = \frac{x_j - \min(x_j)}{\max(x_j) - \min(x_j)}. \quad (86)$$

Standardisasi fitur diberikan oleh

$$x'_j = \frac{x_j - \mu_j}{\sigma_j}. \quad (87)$$

Kemiripan atau jarak antarfitur dapat dihitung menggunakan beberapa metrik. Euclidean distance:

$$d_E(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{j=1}^d (x_j - y_j)^2}. \quad (88)$$

Manhattan distance:

$$d_M(\mathbf{x}, \mathbf{y}) = \sum_{j=1}^d |x_j - y_j|. \quad (89)$$

Cosine similarity:

$$\text{sim}_{\cos}(\mathbf{x}, \mathbf{y}) = \frac{\mathbf{x}^T \mathbf{y}}{\|\mathbf{x}\|_2 \|\mathbf{y}\|_2}. \quad (90)$$

Chi-square distance untuk histogram:

$$d_{\chi^2}(\mathbf{x}, \mathbf{y}) = \frac{1}{2} \sum_{j=1}^d \frac{(x_j - y_j)^2}{x_j + y_j + \epsilon}. \quad (91)$$

15 Evaluasi Kualitas Fitur

Kualitas fitur dapat dievaluasi secara langsung maupun tidak langsung. Evaluasi langsung mengukur sifat statistik fitur, sedangkan evaluasi tidak langsung mengukur performa tugas akhir seperti klasifikasi atau temu-kembali.

Untuk klasifikasi, akurasi didefinisikan sebagai

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}. \quad (92)$$

Presisi dan recall adalah

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}. \quad (93)$$

F1-score diberikan oleh

$$F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}. \quad (94)$$

Untuk temu-kembali citra, precision@K dapat didefinisikan sebagai

$$\text{Precision@K} = \frac{\text{jumlah citra relevan pada } K \text{ hasil teratas}}{K}. \quad (95)$$

16 Perbandingan Metode Ekstraksi Fitur

Metode	Kelebihan	Keterbatasan	Kegunaan
Histogram warna	Sederhana, cepat, mudah diinterpretasikan	Mengabaikan susunan spasial	Pencarian citra berbasis warna
Sobel/Canny	Baik untuk batas objek	Sensitif terhadap derau dan parameter	Deteksi tepi
GLCM	Menangkap relasi spasial intensitas	Bergantung pada kuantisasi dan offset	Analisis tekstur
LBP	Efisien dan kuat terhadap iluminasi monoton	Kurang baik untuk tekstur skala besar	Wajah dan tekstur lokal
Gabor	Menangkap orientasi dan frekuensi	Komputasi relatif mahal	Tekstur dan biometrik
HOG	Kuat untuk bentuk lokal	Kurang semantik	Deteksi manusia/objek
SIFT/ORB	Tahan terhadap perubahan geometris	Bergantung pada titik kunci	Pencocokan citra
CNN	Sangat diskriminatif dan semantik	Butuh data/komputasi besar	Klasifikasi dan deteksi modern

Table 2: Perbandingan beberapa metode ekstraksi fitur citra.

17 Pipeline Umum Image Feature Extraction

Secara umum, sistem ekstraksi fitur citra dapat dirumuskan sebagai pipeline berikut:

$$I \xrightarrow{\text{pra-pemrosesan}} I' \xrightarrow{\text{ekstraksi fitur}} \mathbf{f} \xrightarrow{\text{normalisasi/reduksi}} \mathbf{z} \xrightarrow{\text{model}} \hat{y}. \quad (96)$$

Dalam klasifikasi berbasis fitur, prediksi dapat ditulis sebagai

$$\hat{y} = \arg \max_c P(y = c | \mathbf{z}). \quad (97)$$

Jika menggunakan model linear,

$$\hat{y} = \arg \max_c (\mathbf{w}_c^T \mathbf{z} + b_c). \quad (98)$$

Pemilihan fitur sangat bergantung pada masalah. Untuk klasifikasi tekstur, GLCM, LBP, Gabor, atau CNN dapat digunakan. Untuk pencocokan panorama, SIFT atau ORB lebih sesuai. Untuk klasifikasi objek kompleks, fitur CNN biasanya lebih unggul. Untuk sistem dengan keterbatasan komputasi, fitur sederhana seperti histogram warna, LBP, atau ORB sering lebih praktis.

18 Tantangan dalam Image Feature Extraction

Beberapa tantangan utama dalam ekstraksi fitur citra adalah sebagai berikut.

1. **Variasi iluminasi:** perubahan pencahayaan dapat mengubah intensitas dan warna.
2. **Variasi skala dan rotasi:** objek dapat muncul dalam ukuran atau orientasi berbeda.
3. **Oklusi:** sebagian objek tertutup sehingga fitur global menjadi tidak lengkap.
4. **Derau dan blur:** kualitas citra rendah mengganggu tepi dan tekstur.
5. **Latar belakang kompleks:** fitur objek dapat tercampur dengan fitur latar.
6. **Dimensi tinggi:** fitur terlalu banyak dapat menyebabkan overfitting dan komputasi berat.
7. **Domain shift:** fitur yang baik pada satu dataset belum tentu baik pada dataset lain.

Secara matematis, domain shift dapat dilihat sebagai perbedaan distribusi antara data latih dan data uji:

$$P_{\text{train}}(I, y) \neq P_{\text{test}}(I, y). \quad (99)$$

Ekstraktor fitur yang robust diharapkan menghasilkan distribusi fitur yang tetap stabil:

$$P_{\text{train}}(\phi(I), y) \approx P_{\text{test}}(\phi(I), y). \quad (100)$$

19 Kesimpulan

Image feature extraction adalah fondasi penting dalam pengolahan citra dan visi komputer. Proses ini mengubah citra mentah menjadi representasi numerik yang lebih informatif, ringkas, dan sesuai untuk analisis lanjutan. Fitur tradisional seperti warna, tepi, tekstur, bentuk, HOG, SIFT, dan transformasi frekuensi menawarkan interpretabilitas dan efisiensi. Di sisi lain, fitur berbasis pembelajaran mendalam seperti CNN mampu mempelajari representasi hierarkis yang lebih semantik dan sering memberikan performa tinggi pada tugas kompleks.

Tidak ada satu metode fitur yang selalu terbaik untuk semua kasus. Pemilihan metode harus mempertimbangkan jenis data, tujuan aplikasi, ukuran dataset, kebutuhan interpretabilitas, variasi citra, dan sumber daya komputasi. Dalam praktik modern, pendekatan yang kuat sering menggabungkan pra-pemrosesan yang tepat, ekstraksi fitur yang sesuai, normalisasi, reduksi dimensi, serta evaluasi berbasis tugas akhir.