

Teori Audio Feature Extraction

Ryan Fadhilah Faizal Hakim¹

¹Sains Data, Fakultas Sains dan Teknologi, IKOPIN University

1 Pendahuluan

Audio feature extraction atau ekstraksi fitur audio adalah proses mengubah sinyal audio mentah menjadi representasi numerik yang lebih ringkas, informatif, dan relevan untuk analisis komputasional. Representasi ini digunakan dalam berbagai aplikasi seperti pengenalan ucapan, identifikasi pembicara, klasifikasi genre musik, deteksi emosi, deteksi kejadian akustik, pemisahan sumber suara, temu-kembali audio, analisis bioakustik, serta sistem diagnosis berbasis suara.

Secara umum, sinyal audio kontinu dapat dinyatakan sebagai fungsi waktu

$$x(t) : \mathbb{R} \rightarrow \mathbb{R}, \quad (1)$$

dengan $x(t)$ menyatakan amplitudo tekanan suara pada waktu t . Setelah proses sampling, sinyal audio digital direpresentasikan sebagai deret diskret

$$x[n] = x(nT_s), \quad n = 0, 1, 2, \dots, N - 1, \quad (2)$$

dengan T_s adalah periode sampling dan $f_s = 1/T_s$ adalah frekuensi sampling. Ekstraksi fitur audio membentuk pemetaan

$$\phi(x) = \mathbf{f} \in \mathbb{R}^d, \quad (3)$$

dengan ϕ sebagai ekstraktor fitur dan $\mathbf{f}$ sebagai vektor fitur berdimensi d .

Tujuan utama ekstraksi fitur adalah mengurangi dimensi sinyal mentah tanpa menghilangkan informasi penting. Sinyal audio berdurasi 10 detik dengan sampling rate 16 kHz memiliki 160.000 sampel. Jumlah ini terlalu besar untuk banyak model statistik klasik. Fitur seperti energi, pitch, spectral centroid, MFCC, chroma, dan embedding neural dapat merangkum informasi temporal, spektral, perseptual, maupun semantik secara lebih efisien.

2 Dasar Sinyal Audio Digital

2.1 Sampling dan Kuantisasi

Sampling mengubah sinyal kontinu menjadi sinyal diskret. Jika $x(t)$ dibatasi pita hingga frekuensi maksimum $f_{\max}$, maka berdasarkan prinsip Nyquist, sampling rate harus memenuhi

$$f_s \geq 2f_{\max}. \quad (4)$$

Jika syarat ini tidak dipenuhi, terjadi aliasing, yaitu komponen frekuensi tinggi tampak sebagai frekuensi rendah palsu. Frekuensi Nyquist adalah

$$f_N = \frac{f_s}{2}. \quad (5)$$

Kuantisasi mengubah amplitudo kontinu menjadi level diskret. Untuk kuantisasi uniform B bit dengan rentang amplitudo $[-A, A]$, jumlah level adalah

$$L = 2^B, \quad (6)$$

dan ukuran langkah kuantisasi dapat dihipotesis dengan

$$\Delta = \frac{2A}{L}. \quad (7)$$

Error kuantisasi adalah

$$e_q[n] = x[n] - \hat{x}[n], \quad (8)$$

dengan $\hat{x}[n]$ sebagai nilai hasil kuantisasi.

2.2 Representasi Mono dan Stereo

Audio mono memiliki satu kanal, sedangkan audio stereo memiliki dua kanal kiri dan kanan:

$$\mathbf{x}[n] = \begin{bmatrix} x_L[n] \\ x_R[n] \end{bmatrix}. \quad (9)$$

Konversi stereo ke mono sering dilakukan dengan rata-rata kanal:

$$x_{\text{mono}}[n] = \frac{x_L[n] + x_R[n]}{2}. \quad (10)$$

Namun, untuk tugas yang membutuhkan informasi spasial, fitur antar-kanal seperti beda fase dan beda energi tetap penting.

2.3 Normalisasi Amplitudo

Normalisasi amplitudo digunakan agar skala sinyal konsisten. Peak normalization didefinisikan sebagai

$$x_{\text{norm}}[n] = \frac{x[n]}{\max_m |x[m]| + \epsilon}, \quad (11)$$

dengan ϵ bilangan kecil untuk menghindari pembagian dengan nol. Standardisasi sinyal dapat ditulis sebagai

$$x_z[n] = \frac{x[n] - \mu_x}{\sigma_x}, \quad (12)$$

dengan

$$\mu_x = \frac{1}{N} \sum_{n=0}^{N-1} x[n], \quad \sigma_x = \sqrt{\frac{1}{N} \sum_{n=0}^{N-1} (x[n] - \mu_x)^2}. \quad (13)$$

3 Karakteristik Fitur Audio yang Baik

Fitur audio yang baik memiliki beberapa sifat berikut.

1. **Diskriminatif**: mampu membedakan kelas audio yang berbeda, misalnya ucapan dan musik.
2. **Robust**: stabil terhadap derau, reverberasi, distorsi, perubahan volume, dan variasi perangkat rekam.
3. **Kompak**: berdimensi lebih rendah daripada sinyal mentah.
4. **Relevan secara perseptual**: sesuai dengan cara manusia mendengar, terutama untuk fitur seperti Mel dan MFCC.
5. **Stabil secara temporal**: tidak berubah drastis akibat variasi kecil yang tidak bermakna.
6. **Efisien**: dapat dihitung dengan biaya komputasi yang sesuai kebutuhan aplikasi.

Secara matematis, robust terhadap transformasi tidak relevan T dapat dinyatakan sebagai

$$\phi(T(x)) \approx \phi(x). \quad (14)$$

Sementara itu, sifat diskriminatif dapat dinyatakan melalui jarak fitur:

$$d(\phi(x_i), \phi(x_j)) \text{ kecil jika } y_i = y_j, \quad (15)$$

dan

$$d(\phi(x_i), \phi(x_j)) \text{ besar jika } y_i \neq y_j. \quad (16)$$

4 Framing dan Windowing

Sinyal audio bersifat non-stasioner, artinya sifat statistiknya berubah terhadap waktu. Namun, pada interval pendek, sinyal sering diasumsikan kuasi-stasioner. Karena itu audio dibagi menjadi frame pendek. Frame ke- m dengan panjang N_f dan hop size H didefinisikan sebagai

$$x_m[n] = x[n + mH], \quad n = 0, 1, \dots, N_f - 1. \quad (17)$$

Sebelum analisis frekuensi, frame dikalikan dengan fungsi jendela $w[n]$:

$$y_m[n] = x_m[n]w[n]. \quad (18)$$

Jendela Hamming didefinisikan sebagai

$$w[n] = 0.54 - 0.46 \cos\left(\frac{2\pi n}{N_f - 1}\right), \quad 0 \leq n < N_f. \quad (19)$$

Jendela Hann didefinisikan sebagai

$$w[n] = 0.5 \left(1 - \cos\left(\frac{2\pi n}{N_f - 1}\right)\right). \quad (20)$$

Windowing mengurangi diskontinuitas pada batas frame, sehingga mengurangi spectral leakage pada analisis Fourier.

5 Fitur Domain Waktu

Fitur domain waktu dihitung langsung dari sampel audio. Fitur ini sederhana, cepat, dan berguna untuk analisis energi, onset, segmentasi, serta deteksi aktivitas suara.

5.1 Short-Time Energy

Short-time energy mengukur energi sinyal pada frame pendek:

$$E_m = \sum_{n=0}^{N_f-1} |x_m[n]w[n]|^2. \quad (21)$$

Versi rata-rata energi adalah

$$\bar{E}_m = \frac{1}{N_f} \sum_{n=0}^{N_f-1} |x_m[n]|^2. \quad (22)$$

Energi tinggi sering menunjukkan bagian bersuara, musik keras, atau kejadian akustik kuat.

5.2 Root Mean Square Energy

Root Mean Square (RMS) menggambarkan amplitudo efektif sinyal:

$$\text{RMS}_m = \sqrt{\frac{1}{N_f} \sum_{n=0}^{N_f-1} x_m[n]^2}. \quad (23)$$

Dalam satuan desibel, RMS dapat ditulis sebagai

$$\text{RMS}_{\text{dB}} = 20 \log_{10}(\text{RMS} + \epsilon). \quad (24)$$

5.3 Zero Crossing Rate

Zero Crossing Rate (ZCR) menghitung seberapa sering sinyal berubah tanda dalam satu frame:

$$\text{ZCR}_m = \frac{1}{2N_f} \sum_{n=1}^{N_f-1} |\text{sgn}(x_m[n]) - \text{sgn}(x_m[n-1])|. \quad (25)$$

dengan

$$\text{sgn}(a) = \begin{cases} 1, & a \geq 0, \\ -1, & a < 0. \end{cases} \quad (26)$$

ZCR tinggi sering berhubungan dengan sinyal berfrekuensi tinggi, frikatif dalam ucapan, atau derau.

5.4 Amplitude Envelope

Amplitude envelope menggambarkan perubahan amplitudo maksimum dari waktu ke waktu. Untuk frame ke- m ,

$$A_m = \max_{0 \leq n < N_f} |x_m[n]|. \quad (27)$$

Fitur ini banyak digunakan untuk deteksi onset, dinamika musik, dan segmentasi audio.

5.5 Autocorrelation

Autocorrelation mengukur kemiripan sinyal dengan versi tertundanya:

$$R_x[\ell] = \sum_{n=0}^{N_f-1-\ell} x_m[n]x_m[n+\ell], \quad (28)$$

dengan ℓ sebagai lag. Autocorrelation berguna untuk estimasi pitch karena sinyal periodik menghasilkan puncak pada lag yang sesuai periode fundamental.

6 Analisis Frekuensi dan Spektrum

6.1 Discrete Fourier Transform

Discrete Fourier Transform (DFT) mengubah frame audio dari domain waktu ke domain frekuensi:

$$X_m[k] = \sum_{n=0}^{N_f-1} y_m[n] \exp\left(-j2\pi \frac{kn}{N_f}\right), \quad k = 0, 1, \dots, N_f - 1. \quad (29)$$

Magnitudo spektrum adalah

$$|X_m[k]| = \sqrt{\text{Re}(X_m[k])^2 + \text{Im}(X_m[k])^2}, \quad (30)$$

sedangkan power spectrum adalah

$$P_m[k] = \frac{1}{N_f} |X_m[k]|^2. \quad (31)$$

Frekuensi yang berkorespondensi dengan bin k adalah

$$f_k = \frac{k f_s}{N_f}. \quad (32)$$

6.2 Short-Time Fourier Transform

Short-Time Fourier Transform (STFT) menghitung DFT pada frame-frame berurutan:

$$X(m, k) = \sum_{n=-\infty}^{\infty} x[n] w[n - mH] \exp\left(-j2\pi \frac{kn}{N_{FFT}}\right). \quad (33)$$

Spektrogram adalah representasi waktu-frekuensi dari magnitudo STFT:

$$S(m, k) = |X(m, k)|^2. \quad (34)$$

Dalam skala desibel:

$$S_{\text{dB}}(m, k) = 10 \log_{10}(S(m, k) + \epsilon). \quad (35)$$

Resolusi waktu dan frekuensi saling bertukar. Frame pendek memberikan resolusi waktu baik tetapi resolusi frekuensi buruk. Frame panjang memberikan resolusi frekuensi baik tetapi resolusi waktu buruk.

7 Fitur Spektral

Fitur spektral meringkas bentuk spektrum pada setiap frame. Fitur ini penting untuk klasifikasi suara, analisis timbre, deteksi musik, dan pengenalan lingkungan akustik.

7.1 Spectral Centroid

Spectral centroid menunjukkan pusat massa spektrum dan berkaitan dengan persepsi kecerahan suara:

$$C_m = \frac{\sum_{k=0}^{K-1} f_k |X_m[k]|}{\sum_{k=0}^{K-1} |X_m[k]| + \epsilon}. \quad (36)$$

Nilai centroid tinggi menunjukkan dominasi frekuensi tinggi.

7.2 Spectral Bandwidth

Spectral bandwidth mengukur sebaran spektrum terhadap centroid:

$$B_m = \left(\frac{\sum_{k=0}^{K-1} |X_m[k]| (f_k - C_m)^p}{\sum_{k=0}^{K-1} |X_m[k]| + \epsilon} \right)^{1/p}. \quad (37)$$

Biasanya digunakan $p = 2$ sehingga bandwidth menyerupai simpangan baku spektral.

7.3 Spectral Rolloff

Spectral rolloff adalah frekuensi di bawahnya terdapat proporsi energi tertentu, misalnya 85 persen:

$$\sum_{k=0}^{K_r} |X_m[k]|^2 = \rho \sum_{k=0}^{K-1} |X_m[k]|^2, \quad (38)$$

dengan $\rho \in (0, 1)$, misalnya $\rho = 0.85$. Frekuensi rolloff adalah

$$R_m = f_{K_r}. \quad (39)$$

7.4 Spectral Flatness

Spectral flatness mengukur seberapa mirip spektrum dengan derau putih. Fitur ini didefinisikan sebagai rasio rata-rata geometrik terhadap rata-rata aritmetik:

$$\text{SF}_m = \frac{\left(\prod_{k=0}^{K-1} (P_m[k] + \epsilon) \right)^{1/K}}{\frac{1}{K} \sum_{k=0}^{K-1} (P_m[k] + \epsilon)}. \quad (40)$$

Nilai mendekati 1 menunjukkan spektrum datar seperti noise, sedangkan nilai mendekati 0 menunjukkan spektrum tonal.

7.5 Spectral Flux

Spectral flux mengukur perubahan spektrum antar-frame:

$$\text{Flux}_m = \sum_{k=0}^{K-1} \left(\hat{P}_m[k] - \hat{P}_{m-1}[k] \right)^2, \quad (41)$$

dengan $\hat{P}_m[k]$ sebagai spektrum ternormalisasi. Fitur ini berguna untuk deteksi onset dan perubahan kejadian audio.

7.6 Spectral Contrast

Spectral contrast mengukur perbedaan antara puncak dan lembah spektrum pada beberapa subband. Untuk subband b ,

$$\text{Contrast}_{m,b} = \text{Peak}_{m,b} - \text{Valley}_{m,b}. \quad (42)$$

Fitur ini berguna untuk membedakan suara harmonik dan non-harmonik.

8 Skala Persepsi Pendengaran

Telinga manusia tidak merespons frekuensi secara linear. Karena itu banyak fitur audio menggunakan skala perseptual.

8.1 Skala Mel

Skala Mel memetakan frekuensi linear ke skala yang lebih sesuai dengan persepsi manusia:

$$m = 2595 \log_{10} \left(1 + \frac{f}{700} \right). \quad (43)$$

Inversnya adalah

$$f = 700 \left(10^{m/2595} - 1 \right). \quad (44)$$

Filterbank Mel terdiri dari filter segitiga $H_b[k]$ pada domain frekuensi. Energi Mel pada filter ke- b adalah

$$E_b = \sum_{k=0}^{K-1} P_m[k] H_b[k]. \quad (45)$$

8.2 Skala Bark dan ERB

Skala Bark juga digunakan untuk memodelkan persepsi frekuensi manusia. Salah satu pendekatan umum adalah

$$z(f) = 13 \arctan(0.00076f) + 3.5 \arctan\left(\left(\frac{f}{7500}\right)^2\right). \quad (46)$$

Equivalent Rectangular Bandwidth (ERB) dapat ditulis sebagai

$$\text{ERB}(f) = 24.7 \left(4.37 \frac{f}{1000} + 1\right). \quad (47)$$

9 Mel-Frequency Cepstral Coefficients

Mel-Frequency Cepstral Coefficients (MFCC) adalah fitur audio paling populer dalam pengenalan ucapan dan banyak tugas audio klasik. MFCC meniru sebagian karakteristik persepsi pendengaran manusia dengan filterbank Mel dan transformasi cepstral.

Tahapan MFCC adalah:

1. pre-emphasis;
2. framing dan windowing;
3. menghitung spektrum daya dengan DFT;
4. menerapkan filterbank Mel;
5. mengambil log energi Mel;
6. menerapkan Discrete Cosine Transform (DCT);
7. mengambil sejumlah koefisien awal sebagai fitur.

9.1 Pre-emphasis

Pre-emphasis memperkuat komponen frekuensi tinggi:

$$y[n] = x[n] - \alpha x[n-1], \quad (48)$$

dengan α biasanya mendekati 1, misalnya 0.95 atau 0.97.

9.2 Log Mel Energies

Setelah power spectrum dihitung, energi pada filter Mel adalah

$$E_b = \sum_{k=0}^{K-1} P_m[k] H_b[k], \quad b = 1, 2, \dots, B. \quad (49)$$

Log energi Mel adalah

$$L_b = \log(E_b + \epsilon). \quad (50)$$

9.3 Discrete Cosine Transform pada MFCC

Koefisien MFCC ke- q diperoleh melalui DCT:

$$c_q = \sum_{b=1}^B L_b \cos \left[\frac{\pi q}{B} \left(b - \frac{1}{2} \right) \right], \quad q = 0, 1, \dots, Q-1. \quad (51)$$

Vektor MFCC frame ke- m dapat ditulis sebagai

$$\mathbf{c}_m = [c_0, c_1, \dots, c_{Q-1}]^T. \quad (52)$$

Koefisien rendah menangkap bentuk spektral global, sedangkan koefisien lebih tinggi menangkap detail spektral yang lebih halus.

9.4 Delta dan Delta-Delta MFCC

Untuk menangkap dinamika temporal, digunakan turunan pertama dan kedua. Delta coefficient didefinisikan sebagai

$$\Delta c_m = \frac{\sum_{r=1}^R r(c_{m+r} - c_{m-r})}{2 \sum_{r=1}^R r^2}. \quad (53)$$

Delta-delta coefficient adalah

$$\Delta^2 c_m = \frac{\sum_{r=1}^R r(\Delta c_{m+r} - \Delta c_{m-r})}{2 \sum_{r=1}^R r^2}. \quad (54)$$

Fitur gabungan sering ditulis sebagai

$$\mathbf{f}_m = [\mathbf{c}_m, \Delta \mathbf{c}_m, \Delta^2 \mathbf{c}_m]^T. \quad (55)$$

10 Cepstrum dan Linear Predictive Coding

10.1 Cepstrum

Cepstrum adalah inverse Fourier transform dari log magnitudo spektrum:

$$c[n] = \mathcal{F}^{-1} \{ \log(|X[k]| + \epsilon) \}. \quad (56)$$

Cepstrum memisahkan komponen eksitasi dan filter saluran vokal pada ucapan. Domain cepstral menggunakan istilah quefrency, yaitu analog waktu untuk cepstrum.

10.2 Linear Predictive Coding

Linear Predictive Coding (LPC) memodelkan sampel audio sebagai kombinasi linear sampel sebelumnya:

$$\hat{x}[n] = \sum_{p=1}^P a_p x[n-p]. \quad (57)$$

Error prediksi adalah

$$e[n] = x[n] - \hat{x}[n] = x[n] - \sum_{p=1}^P a_p x[n-p]. \quad (58)$$

Koefisien LPC dipilih untuk meminimalkan energi error:

$$J = \sum_n e[n]^2. \quad (59)$$

Model filter all-pole LPC adalah

$$H(z) = \frac{G}{1 - \sum_{p=1}^P a_p z^{-p}}. \quad (60)$$

LPC banyak digunakan untuk analisis ucapan karena dapat merepresentasikan resonansi saluran vokal atau formant.

11 Pitch, Harmonik, dan Fitur Tonal

11.1 Pitch dan Fundamental Frequency

Pitch berkaitan dengan frekuensi fundamental F_0 . Pada sinyal periodik dengan periode T_0 , frekuensi fundamental adalah

$$F_0 = \frac{1}{T_0}. \quad (61)$$

Dalam domain diskret, jika puncak autocorrelation terjadi pada lag ℓ_0 , maka estimasi pitch adalah

$$\hat{F}_0 = \frac{f_s}{\ell_0}. \quad (62)$$

11.2 Harmonic-to-Noise Ratio

Harmonic-to-Noise Ratio (HNR) mengukur perbandingan komponen harmonik terhadap komponen derau:

$$\text{HNR} = 10 \log_{10} \left(\frac{E_{\text{harmonic}}}{E_{\text{noise}} + \epsilon} \right). \quad (63)$$

HNR banyak digunakan pada analisis kualitas suara dan patologi suara.

11.3 Chroma Features

Chroma merepresentasikan energi berdasarkan 12 kelas nada musik, tanpa memperhatikan oktaf. Jika $p \in \{0, 1, \dots, 11\}$ adalah kelas pitch, chroma dapat didefinisikan sebagai

$$C_m[p] = \sum_{k \in \mathcal{K}_p} |X_m[k]|^2, \quad (64)$$

dengan $\mathcal{K}_p$ adalah himpunan bin frekuensi yang termasuk kelas pitch p . Normalisasi chroma sering dilakukan dengan

$$\hat{C}_m[p] = \frac{C_m[p]}{\sum_{q=0}^{11} C_m[q] + \epsilon}. \quad (65)$$

Chroma sangat berguna untuk pengenalan akor, estimasi kunci lagu, dan pencocokan musik.

12 Fitur Rhythm dan Temporal Musik

12.1 Onset Strength

Onset adalah awal kejadian suara, misalnya pukulan drum atau permulaan nada. Onset strength dapat dihitung dari perubahan spektrum positif:

$$O[m] = \sum_{k=0}^{K-1} \max(0, |X_m[k]| - |X_{m-1}[k]|). \quad (66)$$

12.2 Tempo dan Beat

Tempo menggambarkan kecepatan musik dalam beats per minute (BPM). Jika periode beat dalam satuan detik adalah T_b , maka

$$\text{BPM} = \frac{60}{T_b}. \quad (67)$$

Estimasi tempo sering dilakukan dengan autocorrelation pada onset envelope:

$$R_O[\ell] = \sum_m O[m]O[m + \ell]. \quad (68)$$

Lag dengan puncak autocorrelation dapat diubah menjadi estimasi BPM.

13 Fitur Berbasis Wavelet dan Time-Frequency Lain

13.1 Continuous Wavelet Transform

Continuous Wavelet Transform (CWT) menganalisis sinyal dengan fungsi wavelet yang diskalakan dan digeser:

$$W_x(a, b) = \frac{1}{\sqrt{|a|}} \int_{-\infty}^{\infty} x(t) \psi^* \left(\frac{t-b}{a} \right) dt, \quad (69)$$

dengan a sebagai skala, b sebagai translasi, ψ sebagai mother wavelet, dan $*$ menyatakan konjugat kompleks.

13.2 Discrete Wavelet Transform

Discrete Wavelet Transform (DWT) mendekomposisi sinyal menjadi koefisien aproksimasi dan detail. Energi pada subband s dapat digunakan sebagai fitur:

$$E_s = \sum_n |w_s[n]|^2. \quad (70)$$

Fitur wavelet berguna untuk sinyal transien karena menyediakan resolusi waktu baik pada frekuensi tinggi dan resolusi frekuensi baik pada frekuensi rendah.

14 Fitur Statistik Agregat

Karena fitur audio biasanya dihitung per frame, satu audio penuh perlu direpresentasikan sebagai statistik global. Jika f_m adalah nilai fitur pada frame ke- m , maka statistik umum meliputi

$$\mu_f = \frac{1}{M} \sum_{m=1}^M f_m, \quad (71)$$

$$\sigma_f = \sqrt{\frac{1}{M} \sum_{m=1}^M (f_m - \mu_f)^2}, \quad (72)$$

$$\min_f = \min_m f_m, \quad (73)$$

$$\max_f = \max_m f_m. \quad (74)$$

Skewness dan kurtosis dapat ditulis sebagai

$$\text{skew}(f) = \frac{\frac{1}{M} \sum_{m=1}^M (f_m - \mu_f)^3}{\sigma_f^3 + \epsilon}, \quad (75)$$

$$\text{kurt}(f) = \frac{\frac{1}{M} \sum_{m=1}^M (f_m - \mu_f)^4}{\sigma_f^4 + \epsilon}. \quad (76)$$

15 Fitur Berbasis Pembelajaran Mendalam

15.1 Log-Mel Spectrogram sebagai Input Neural Network

Dalam pembelajaran mendalam, audio sering diubah menjadi log-Mel spectrogram:

$$\mathbf{L}[m, b] = \log \left(\sum_{k=0}^{K-1} P_m[k] H_b[k] + \epsilon \right). \quad (77)$$

Representasi ini berbentuk matriks waktu-frekuensi dan dapat diproses oleh Convolutional Neural Network (CNN), Recurrent Neural Network (RNN), Transformer, atau arsitektur hybrid.

15.2 Convolutional Neural Network untuk Audio

Konvolusi dua dimensi pada spectrogram dapat ditulis sebagai

$$Z_q(i, j) = \sum_c \sum_u \sum_v W_{q,c}(u, v) A_c(i - u, j - v) + b_q. \quad (78)$$

Aktivasi ReLU adalah

$$A_q(i, j) = \max(0, Z_q(i, j)). \quad (79)$$

CNN dapat mempelajari pola lokal seperti formant, harmonik, transient, dan tekstur spektral.

15.3 Recurrent Neural Network dan Temporal Embedding

Untuk menangkap dinamika temporal, RNN memperbarui state tersembunyi:

$$\mathbf{h}_t = \sigma(\mathbf{W}_x \mathbf{x}_t + \mathbf{W}_h \mathbf{h}_{t-1} + \mathbf{b}). \quad (80)$$

Embedding audio dapat diambil dari state akhir atau pooling seluruh state:

$$\mathbf{z} = \frac{1}{T} \sum_{t=1}^T \mathbf{h}_t. \quad (81)$$

15.4 Transformer dan Attention

Transformer menggunakan mekanisme attention. Untuk query Q , key K , dan value V , scaled dot-product attention didefinisikan sebagai

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V. \quad (82)$$

Pada audio, Transformer dapat memodelkan hubungan jangka panjang antar-frame, misalnya struktur ujaran atau pola musik.

15.5 Autoencoder Audio

Autoencoder mempelajari representasi laten dengan merekonstruksi input:

$$\mathbf{z} = f_{\theta}(\mathbf{x}), \quad \hat{\mathbf{x}} = g_{\psi}(\mathbf{z}). \quad (83)$$

Loss rekonstruksi dapat ditulis sebagai

$$\mathcal{L}_{\text{rec}} = \|\mathbf{x} - \hat{\mathbf{x}}\|_2^2. \quad (84)$$

Jika input berupa spectrogram, loss dapat dihitung pada domain waktu-frekuensi:

$$\mathcal{L}_{\text{spec}} = \|\mathbf{S} - \hat{\mathbf{S}}\|_1. \quad (85)$$

16 Normalisasi dan Reduksi Dimensi

Fitur audio dari berbagai jenis memiliki skala berbeda. Normalisasi penting sebelum klasifikasi atau clustering. Standardisasi fitur ke- j adalah

$$z_j = \frac{x_j - \mu_j}{\sigma_j}. \quad (86)$$

Min-max normalization adalah

$$z_j = \frac{x_j - \min(x_j)}{\max(x_j) - \min(x_j) + \epsilon}. \quad (87)$$

Principal Component Analysis (PCA) dapat digunakan untuk reduksi dimensi. Untuk data fitur $\mathbf{x}_1, \dots, \mathbf{x}_n$, matriks kovarians adalah

$$\mathbf{S} = \frac{1}{n-1} \sum_{i=1}^n (\mathbf{x}_i - \boldsymbol{\mu})(\mathbf{x}_i - \boldsymbol{\mu})^T. \quad (88)$$

PCA mencari eigenvector

$$\mathbf{S}\mathbf{u}_r = \lambda_r \mathbf{u}_r, \quad (89)$$

dan memproyeksikan fitur ke ruang berdimensi lebih rendah:

$$\mathbf{z} = \mathbf{U}_R^T(\mathbf{x} - \boldsymbol{\mu}). \quad (90)$$

17 Metrik Kemiripan Fitur Audio

Dalam klasifikasi, clustering, dan temu-kembali audio, fitur dibandingkan menggunakan metrik jarak. Euclidean distance:

$$d_E(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{j=1}^d (x_j - y_j)^2}. \quad (91)$$

Manhattan distance:

$$d_M(\mathbf{x}, \mathbf{y}) = \sum_{j=1}^d |x_j - y_j|. \quad (92)$$

Cosine similarity:

$$\text{sim}_{\cos}(\mathbf{x}, \mathbf{y}) = \frac{\mathbf{x}^T \mathbf{y}}{\|\mathbf{x}\|_2 \|\mathbf{y}\|_2}. \quad (93)$$

Dynamic Time Warping (DTW) digunakan untuk membandingkan dua urutan fitur dengan panjang atau tempo berbeda. Jika $D(i, j)$ adalah biaya kumulatif, maka

$$D(i, j) = d(\mathbf{x}_i, \mathbf{y}_j) + \min\{D(i-1, j), D(i, j-1), D(i-1, j-1)\}. \quad (94)$$

DTW sering digunakan pada pengenalan ucapan, pencocokan melodi, dan perbandingan time series audio.

18 Evaluasi Fitur Audio

Kualitas fitur audio dapat dievaluasi berdasarkan performa tugas akhir. Untuk klasifikasi, metrik umum adalah akurasi:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}. \quad (95)$$

Presisi dan recall adalah

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}. \quad (96)$$

F1-score adalah

$$F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}. \quad (97)$$

Untuk deteksi kejadian audio, onset, atau voice activity detection, evaluasi dapat dilakukan pada level frame. Jika $\hat{y}_m$ adalah prediksi frame dan y_m label sebenarnya, loss klasifikasi biner dapat ditulis sebagai

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{M} \sum_{m=1}^M [y_m \log \hat{y}_m + (1 - y_m) \log(1 - \hat{y}_m)]. \quad (98)$$

19 Perbandingan Metode Ekstraksi Fitur Audio

20 Pipeline Umum Audio Feature Extraction

Pipeline ekstraksi fitur audio dapat dirumuskan sebagai

$$\begin{aligned} x[n] &\xrightarrow{\text{pra-pemrosesan}} \tilde{x}[n] \xrightarrow{\text{framing}} x_m[n] \\ &\xrightarrow{\text{ekstraksi fitur}} \mathbf{f}_m \xrightarrow{\text{agregasi}} \mathbf{z} \xrightarrow{\text{model}} \hat{y}. \end{aligned} \quad (99)$$

Fitur	Kelebihan	Keterbatasan	Aplikasi
Energy/RMS	Sangat cepat dan mudah dihitung	Kurang diskriminatif untuk kelas kompleks	Deteksi aktivitas suara
ZCR	Baik untuk indikasi frekuensi tinggi dan noise	Sensitif terhadap derau	Segmentasi ucapan
Spectral centroid	Menggambarkan kecerahan suara	Tidak cukup sendiri untuk klasifikasi kompleks	Musik dan timbre
Spectral flux	Menangkap perubahan spektrum	Bergantung pada kualitas STFT	Onset detection
MFCC	Kuat dan populer untuk ucapan	Dapat kehilangan detail temporal halus	Speech recognition
Chroma	Invarian terhadap oktaf	Kurang cocok untuk audio non-musikal	Analisis musik
LPC	Merepresentasikan saluran vokal	Sensitif terhadap asumsi model all-pole	Analisis ucapan
Wavelet	Baik untuk transient	Pemilihan wavelet berpengaruh besar	Deteksi kejadian
Deep embedding	Sangat diskriminatif dan semantik	Butuh data dan komputasi besar	Audio modern skala besar

Table 1: Perbandingan beberapa fitur audio umum.

Untuk klasifikasi, model probabilistik menghasilkan

$$\hat{y} = \arg \max_c P(y = c | \mathbf{z}). \quad (100)$$

Untuk model linear,

$$\hat{y} = \arg \max_c (\mathbf{w}_c^T \mathbf{z} + b_c). \quad (101)$$

Pemilihan fitur bergantung pada tugas. Untuk pengenalan ucapan, MFCC, filterbank Mel, pitch, dan embedding neural sering digunakan. Untuk analisis musik, chroma, tempo, spectral contrast, dan onset strength sangat relevan. Untuk deteksi kejadian akustik, log-Mel spectrogram, spectral flux, RMS, dan CNN embedding sering efektif. Untuk aplikasi ringan, fitur domain waktu dan spektral sederhana dapat menjadi pilihan karena efisien.

21 Tantangan dalam Audio Feature Extraction

Beberapa tantangan utama dalam ekstraksi fitur audio adalah sebagai berikut.

1. **Derau:** suara latar dapat mengubah energi, spektrum, dan estimasi pitch.
2. **Reverberasi:** pantulan ruangan memperpanjang sinyal dan mengaburkan temporal detail.
3. **Variasi perangkat:** mikrofon dan codec berbeda menghasilkan karakteristik spektral berbeda.
4. **Variasi pembicara:** usia, gender, aksen, dan kondisi vokal memengaruhi fitur ucapan.
5. **Non-stasioneritas:** karakteristik audio berubah cepat terhadap waktu.

6. **Overlap sumber:** beberapa sumber suara dapat muncul bersamaan.
7. **Domain shift:** distribusi data latih dan data uji dapat berbeda.

Domain shift dapat dinyatakan sebagai

$$P_{\text{train}}(x, y) \neq P_{\text{test}}(x, y). \quad (102)$$

Ekstraktor fitur yang baik diharapkan menghasilkan distribusi representasi yang lebih stabil:

$$P_{\text{train}}(\phi(x), y) \approx P_{\text{test}}(\phi(x), y). \quad (103)$$

22 Kesimpulan

Audio feature extraction adalah tahap fundamental dalam pemrosesan sinyal audio dan machine listening. Proses ini mengubah sinyal audio mentah menjadi representasi numerik yang lebih ringkas dan bermakna. Fitur domain waktu seperti RMS dan ZCR mudah dihitung dan berguna untuk analisis cepat. Fitur spektral seperti centroid, bandwidth, rolloff, flatness, dan flux menggambarkan struktur frekuensi. MFCC dan log-Mel spectrogram menghubungkan analisis audio dengan persepsi manusia. Fitur tonal seperti pitch dan chroma penting untuk musik dan ucapan. Fitur deep learning memberikan representasi semantik yang kuat, terutama ketika data dan komputasi tersedia.

Tidak ada fitur tunggal yang selalu terbaik. Pilihan fitur harus disesuaikan dengan jenis audio, tujuan aplikasi, ukuran dataset, kondisi derau, kebutuhan interpretabilitas, dan sumber daya komputasi. Sistem modern sering menggabungkan fitur klasik, representasi time-frequency, normalisasi, reduksi dimensi, dan embedding neural untuk memperoleh performa yang kuat dan robust.